



UNIVERSIDADE ESTADUAL PAULISTA “JÚLIO DE MESQUITA FILHO” - UNESP
PROGRAMA DE PÓS-GRADUAÇÃO EM AGRONOMIA (CIÊNCIA DO SOLO)
CÂMPUS DE JABOTICABAL



**Aprendizado de máquina na modelagem
temporal da emissão de CO₂ do solo em áreas
agrícolas no Cerrado brasileiro**

Discente: Kleve Freddy Ferreira Canteral
Orientador: Prof. Dr. Alan Rodrigo Panosso
Coorientador: Prof. Dr. José Nelson Peruzzi

Jaboticabal – SP




2020



Fonte: wwf.org.br

- ✓ Degradação do meio ambiente e mudanças climáticas (IPCC, 2014; UNFCCC, 2013);
- ✓ Influência antrópica e mudanças de uso da terra (Noojipady et al., 2017);
- ✓ Aumento de 1 °C de aquecimento global (0,8 a 1,2 °C) (Olsson et al., 2019).

Gases de Efeito Estufa (GEE)



Vapores
d'água

Dinâmica de emissão de CO_2 do solo (FCO_2)

Produção de gases

- ✓ Ação de microrganismos na **decomposição da MOS**;
- ✓ Respiração das raízes das plantas.



Transporte de gases

- ✓ Estrutura física do solo;
- ✓ Fluxo de gases no solo.

Tempo

Condições
ambientais

Práticas de
manejo

Abordagem estatística convencional

- ✓ Década de 1960: **métodos matemáticos e estatísticos** no estudo da **ciência do solo** (Mc Bratney et al., 2002).
- ✓ Últimos 30 anos: uso de **métodos não lineares**.

Machine learning

- ✓ Fornecem modelos eficazes quando **aprendem e simulam** processos (Zendehboudi et al., 2018).
- ✓ **RNAs** simulam a estrutura e função do **sistema nervoso biológico** e identificam relações por meio do **processo de aprendizado** e o uso de processadores chamados neurônios (Prieto et al., 2016).
- ✓ **Múltiplas aplicações** em setores diversos:
 - ✓ Mapeamento de suscetibilidade e deslizamentos de terra (Chen et al., 2017);
 - ✓ Estimção da **MOS** (Fernandes et al., 2019);
 - ✓ Modelagem de **GEE** de transportes rodoviários (Gopalakrishnan et al., 2011; Alhindawi et al., 2019);
 - ✓ Predição da **respiração do solo** em áreas de cana-de-açúcar (Freitas et al., 2018).

Hipótese

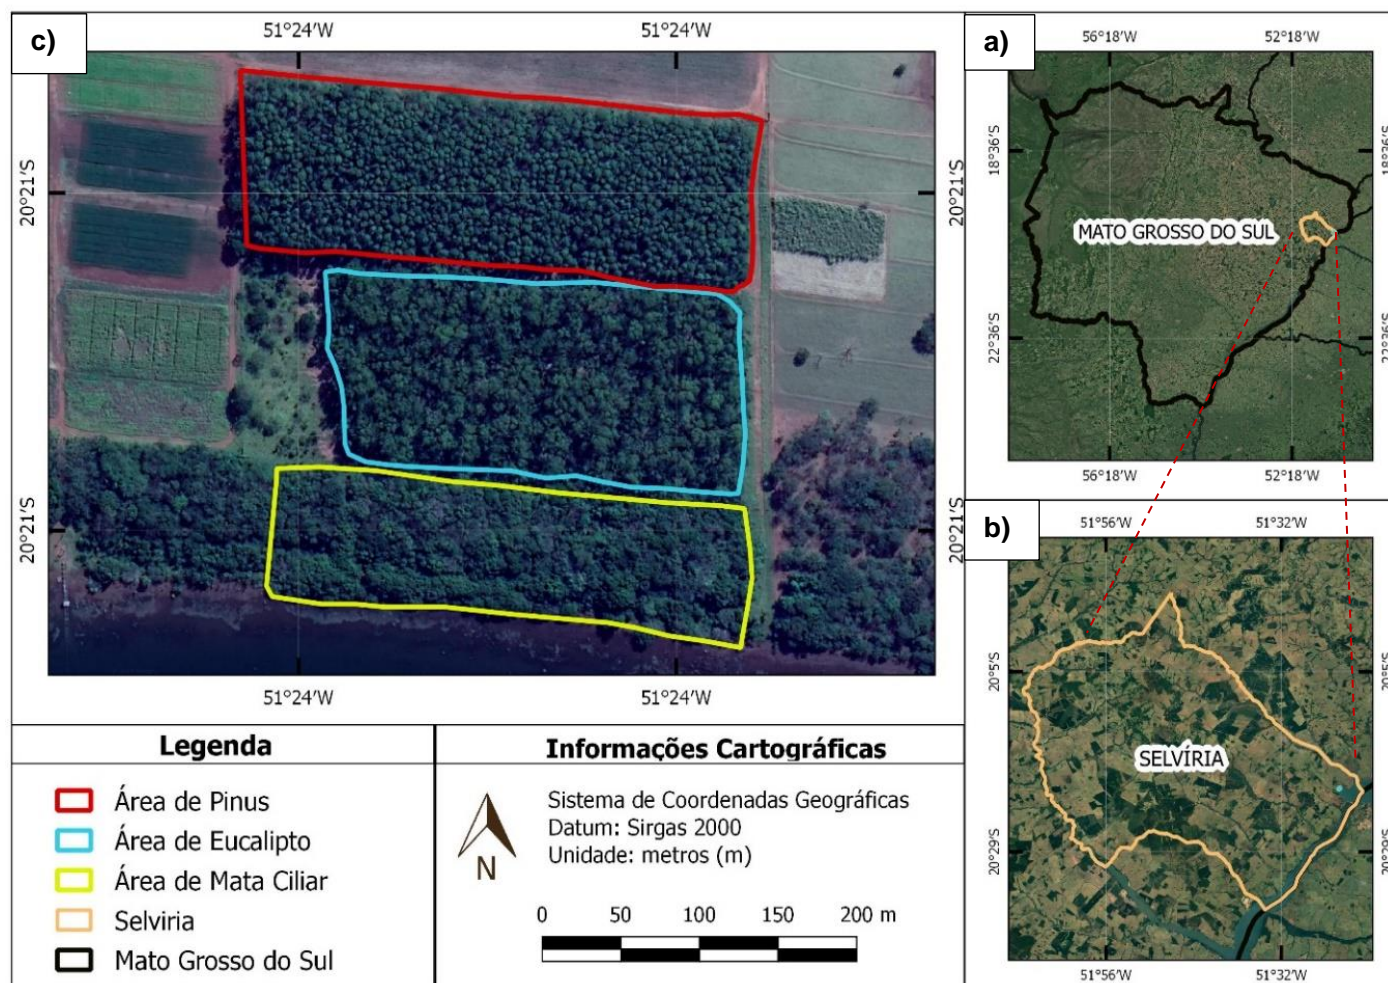
A aplicação de técnicas de aprendizado de máquina geram modelos preditivos para explicar o padrão de variabilidade temporal da emissão de CO₂ do solo, a partir de atributos físico-químicos do solo.

1

Uso de RNAs e ANFIS para modelar os padrões de variabilidade temporal da emissão de CO₂ do solo em área de eucalipto, pinus e mata nativa, no município de Selvíria (MS), no bioma Cerrado.

2


Identificar qual é a técnica mais eficiente.



Amostragem de campo

- ✓ Estudo de campo (novembro de 2015 a maio de 2016);
- ✓ Solo classificado como Latossolo Vermelho distrófico;
- ✓ Topografia moderadamente plana e ondulada;
- ✓ Clima tropical úmido (Aw) com estações chuvosas no verão e seca no inverno;
- ✓ Precipitação média de 1370 mm e temperatura de 23,5 °C.

Figura 1. Mapa das áreas de estudo localizadas no município de Selvíria, MS. a) Estado do Mato Grosso do Sul, Brasil Central; b) Município de Selvíria; c) Áreas de florestas plantadas: pinus, eucalipto e mata ciliar, respectivamente.



Determinação da emissão de CO_2 do solo, temperatura e umidade do solo

- ✓ Medições: 20 dias ao longo de 193 dias de estudo;
- ✓ Avaliações durante a manhã (7 às 12 h);
- ✓ LI-8100; LI-COR Bioscience, Nebraska, EUA;
- ✓ 25 pontos de amostragem (PVC);
- ✓ Ts: termômetro digital.

Figura 2. a) Sistema LI-8100 interligado à câmara de solos; b) câmara para solo inserida sobre o colar de PVC; c) colar de PVC inserido no solo na área de pinus.

Determinação de variáveis químicas e físicas do solo

Análises químicas

Alumínio (Al)
Magnésio (Mg)
Acidez potencial (H + Al)
Matéria orgânica do solo (MOS)
Potássio (K)
Fósforo (P)
Cálcio (Ca)
pH
Soma de Bases (SB)
Saturação por bases (V%)
Capacidade de troca de cátions (CTC)
Estoque de carbono do solo (EstC)
Estoque de nitrogênio do solo (EstN)

Análises físicas

Densidade do solo (Ds)
Macroporosidade (macro)
Microporosidade (micro)
Volume total de poros (VTP)
Areia
Silte
Argila
Porosidade livre de água (PLA)
Grau de humificação da matéria orgânica (H_{LIFS})



Análise de Correlação Canônica (ACC)

$$S_{(p+q) \times (p+q)} = \begin{bmatrix} S_{(p \times p)}^{11} & S_{(p \times q)}^{12} \\ S_{(q \times p)}^{21} & S_{(q \times q)}^{22} \end{bmatrix}$$

p: primeiro grupo de variáveis canônicas;

q: segundo par de variáveis canônicas.

$$S_{(p+q) \times (p+q)} = \begin{bmatrix} S_{(\text{dinâmicos} \times \text{dinâmicos})}^{11} & S_{(\text{dinâmicos} \times \text{físico-químicos})}^{12} \\ S_{(\text{físico-químicos} \times \text{dinâmicos})}^{21} & S_{(\text{físico-químicos} \times \text{físico-químicos})}^{22} \end{bmatrix}$$


Redes Neurais Artificiais (RNAs)

Multilayer Perceptron MLP

Camadas
de entrada

Camada
escondida

Camada
de saída




Regressão Generalizada GRNN

Camadas
de entrada

Camadas
escondidas

Camada
de saída




Função de Base Radial RBF

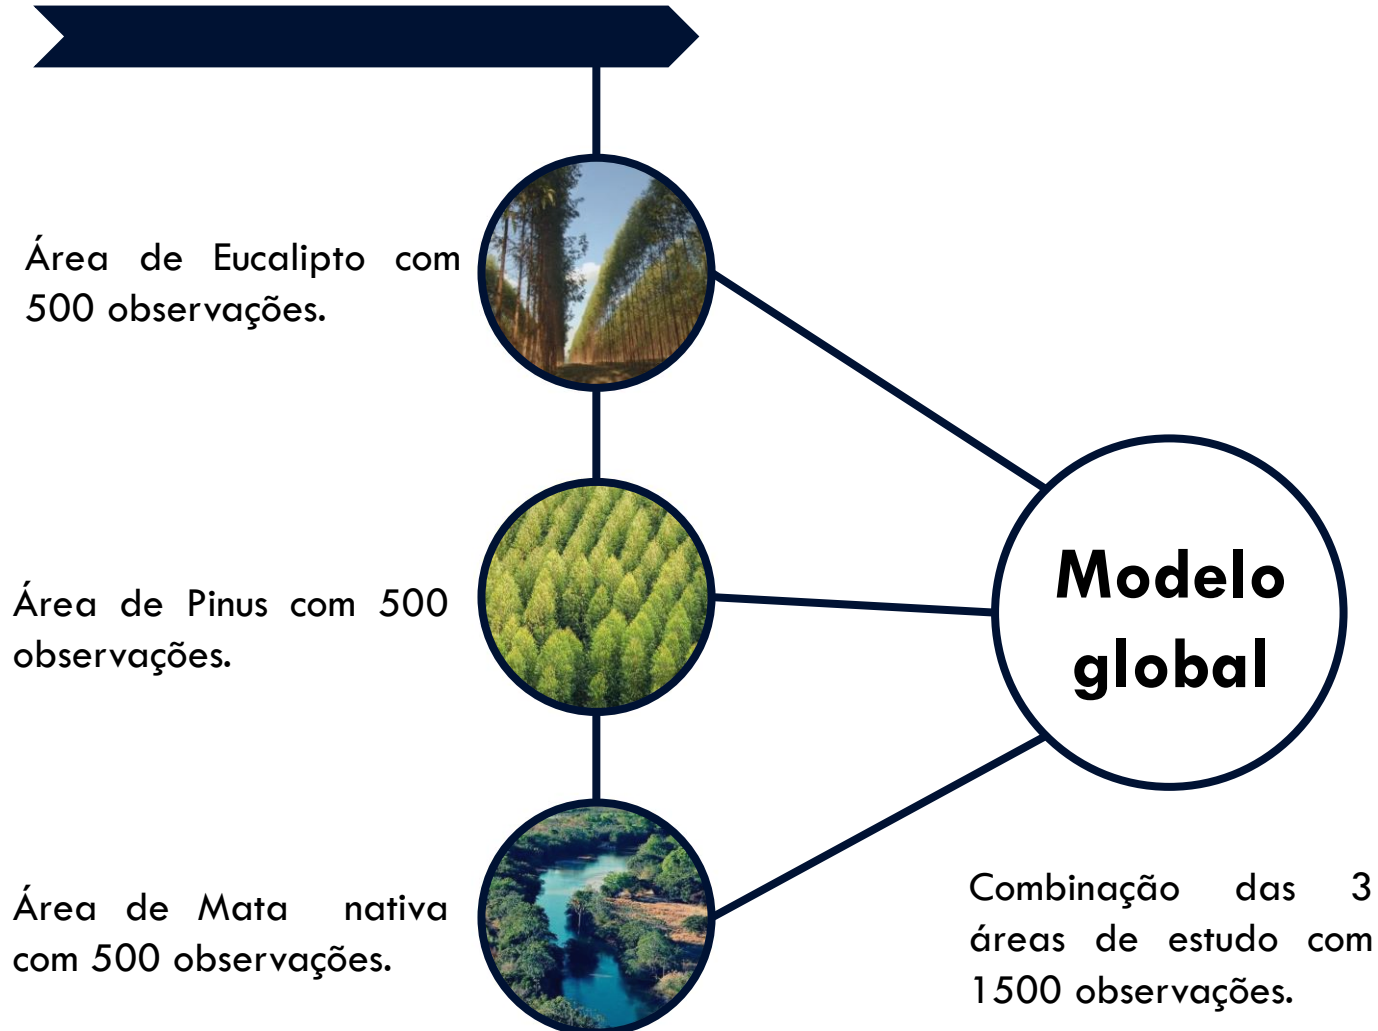
Camadas
de entrada

Camada
escondida

Camada
de saída

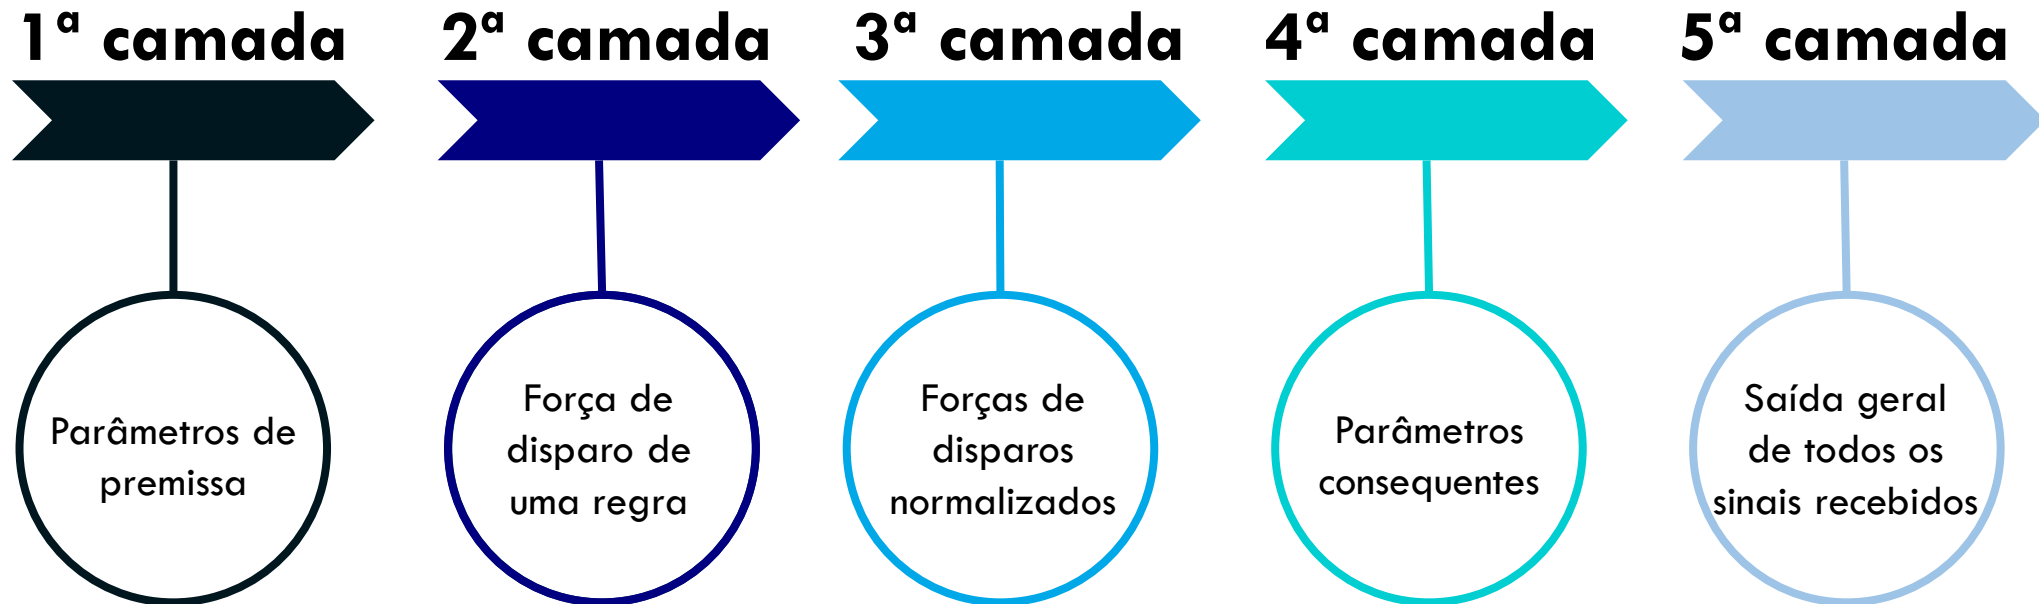


Modelos individuais



Número de ciclos igual a 50 (Haykin, 2001)

Sistema de Inferência Adaptativo Neuro-Difuso (ANFIS)



Critérios para avaliação dos modelos

Erro médio absoluto

$$MEA = \frac{\sum_{i=1}^N (Y_{obs1} - Y_{est1})}{N}$$

Erro quadrático médio da raiz

$$RMSE = \sqrt{\frac{\sum_{i=1}^N (Y_{obs1} - Y_{est1})^2}{N}}$$

Erro padrão médio absoluto

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left(\frac{|(A_i - P_i)|}{A_i} 100 \right)$$

Índice de concordância

$$d = 1 - \frac{\sum_{i=1}^N (Y_{obs1} - Y_{est1})^2}{\sum_{i=1}^N (|Y_{est1} - \bar{Y}| + |Y_{obs1} - \bar{Y}|)^2}$$

Coeficiente de confiança

$$c = r d$$

Coeficiente de correlação de Pearson

$$r = \frac{(N \sum_{i=1}^N (X_{obs1} Y_{obs1}) - \sum_{i=1}^N X_{obs1} \sum_{i=1}^N Y_{obs1})}{\sqrt{\left((N \sum_{i=1}^N X_{obs1}^2 - (\sum_{i=1}^N X_{obs1})^2) \right) \left((N \sum_{i=1}^N Y_{obs1}^2 - (\sum_{i=1}^N Y_{obs1})^2) \right)}}$$

Onde:

A_i = valor real;

P_i = valor previsto;

N = número de dados;

X_{obs1} = valores observados de X ;

Y_{obs1} = valores observados de Y ;

\bar{Y} = média observada de Y .

Análise de Correlação Canônica

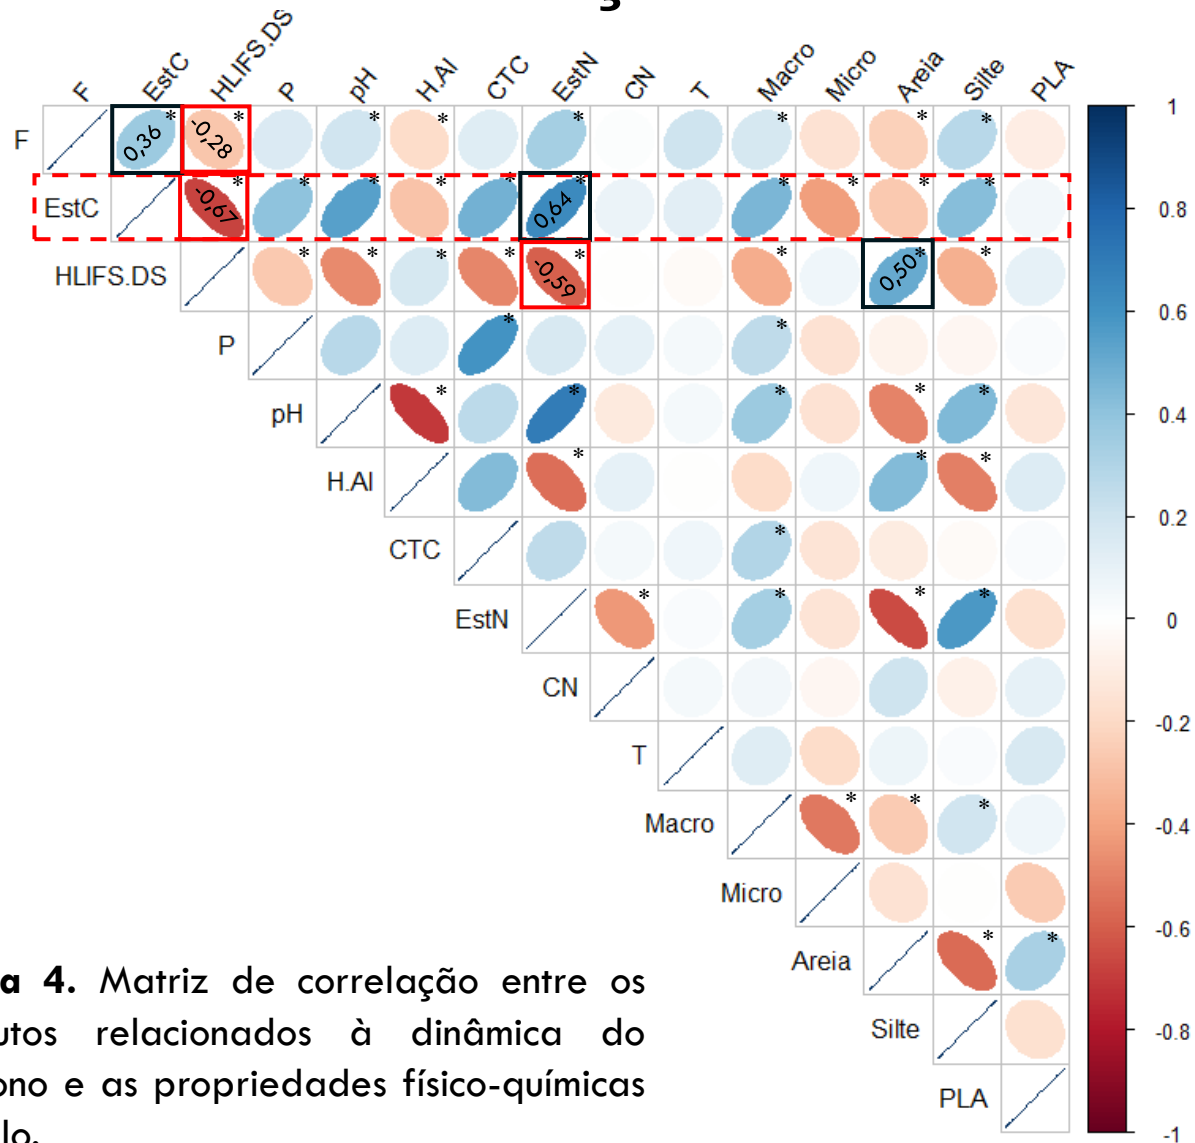



Figura 4. Matriz de correlação entre os atributos relacionados à dinâmica do carbono e as propriedades físico-químicas do solo.

Dinâmica do carbono do solo

Manejo adequado do solo



Maximiza o EstC no solo (Souza et al., 2018)



Análise de Correlação Canônica

Tabela 1. Autovalores e correlações canônicas para os atributos dinâmicos e físico-químicos do solo.

Pares de variáveis canônicas	(U1, V1)	(U2, V2)	(U3, V3)
Correlação canônica	0,874	0,589	0,312
R² canônico (autovalores)	0,764	0,347	0,097
χ^2	2939,50	787,66	152,57
Graus de Liberdade	36	22	10
Valor p	< 0,0001	< 0,0001	< 0,0001

Atuam de forma interdependente




Figura 5. Gráfico de dispersão do primeiro par de variáveis canônicas padronizadas. Atributos dinâmicos do solo (U1): FCO₂, EstC, H_{LIFS.DS}; atributos físico-químicos do solo (V1): P, pH, H + Al, CTC, EstN, CN, Us, Ts, macro, micro, areia, silte e PLA.

Análise de Correlação Canônica

Variável	Cargas canônicas			Cargas canônicas cruzadas		
	U1	U2	U3	V1	V2	V3
FCO ₂	-0,460	0,004	0,888	-0,402	0,002	0,277
H _{LIFS,DS}	-0,993	0,053	-0,107	-0,868	0,031	-0,033
EstC	0,711	0,701	0,051	0,622	0,413	0,016
PVTE (%)	56,79	16,47	26,74			
IR	51,69					
	Cargas canônicas			Cargas canônicas cruzadas		
	V1	V2	V3	U1	U2	U3
P	-0,399	0,030	-0,027	-0,456	0,051	-0,087
pH	-0,545	-0,124	-0,059	-0,624	-0,210	-0,189
H + Al	0,296	-0,045	-0,057	0,338	-0,076	-0,182
CTC	-0,480	-0,200	-0,097	-0,549	-0,340	-0,311
EstN	-0,654	-0,184	0,038	-0,748	-0,313	0,122
CN	-0,080	0,080	-0,024	-0,092	0,135	-0,076
Ts	-0,138	0,092	0,155	-0,158	0,156	0,497
Ma	-0,461	-0,050	-0,040	-0,528	-0,085	-0,129
Mi	0,400	-0,312	0,034	0,458	-0,530	0,110
Areia	0,305	0,412	-0,104	0,349	0,699	-0,332
Silte	-0,440	-0,072	0,079	-0,503	-0,122	0,255
PLA	-0,029	0,189	-0,127	-0,033	0,320	-0,406
PVTE (%)	20,59	10,03	6,74			
IR	19,86					

Atributos químicos

✓ Agregação e dinâmica da água no solo;
✓ Ciclagem e retenção de nutrientes do solo.

CTC
pH

MOS

Temperatura do solo:
✓ Fisiológica;
✓ Bioquímica.

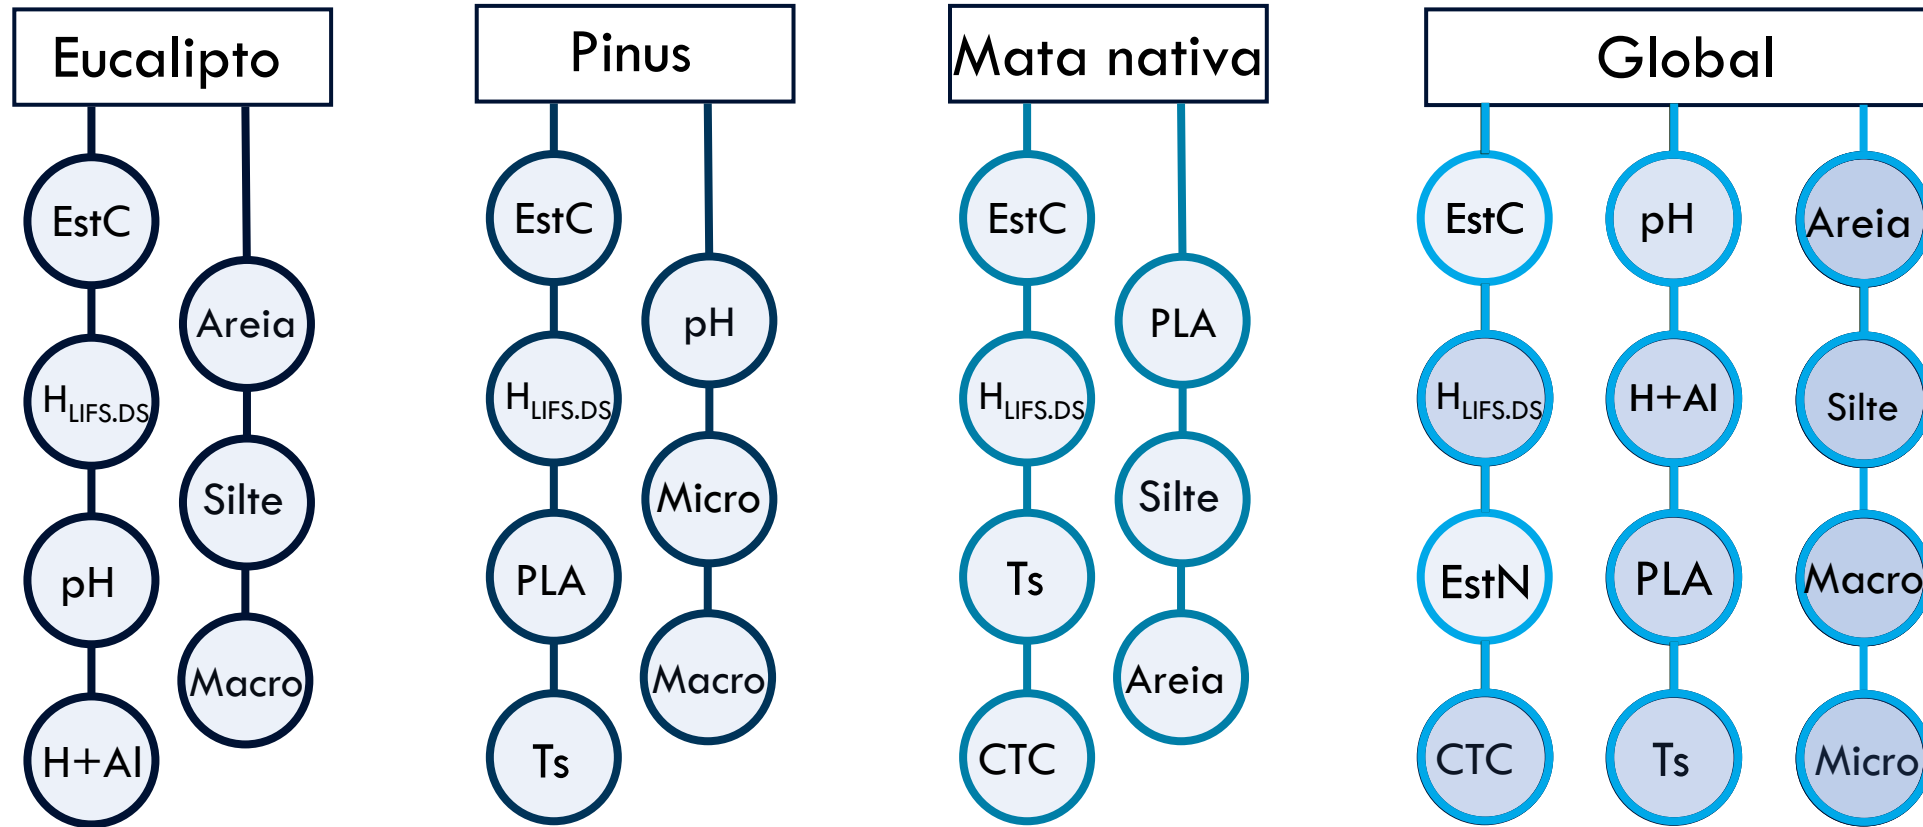
Índice de redundância

EstN, CTC e H + Al

Variabilidade temporal da FCO₂

Tabela 2. Correlações entre os atributos estudados incluindo as cargas canônicas e cargas canônicas cruzadas. FCO₂: emissão de CO₂ do solo; H_{LIFS,DS}: interação entre o grau de humificação da matéria orgânica e a densidade do solo; EstC: estoque de carbono do solo; P: fósforo; H + Al: acidez potencial; CTC: capacidade de troca de cátions; EstN: estoque de nitrogênio do solo; CN: relação carbono/nitrogênio; Ts: temperatura do solo; Ma: macroporosidade do solo; Mi: microporosidade do solo; PVTE (%): proporção de variação total explicada; IR: índice de redundância.

Redes Neurais Artificiais



Manejo \Rightarrow Propriedades físico-químicas \Rightarrow Dinâmica FCO₂

Tabela 3. Desempenho dos índices estatísticos para as fases de calibração e validação das redes neurais artificiais.

Área de eucalipto										
Topologia	Fase	MEA	RMSE	MAPE	r	d	Classificação (c)	F	Valor-p	
RNA 1	Calibração	0,73	0,80	0,15	0,89	0,94	0,83	Muito bom	931,60	< 0,0001
GRNN 7-250-2 ^a	Validação	0,93	1,01	0,19	0,77	0,87	0,67	Bom	161,90	< 0,0001
RNA 2	Calibração	0,84	0,94	0,16	0,85	0,92	0,78	Muito bom	635,20	< 0,0001
RBF 7-29-1	Validação	0,87	0,98	0,18	0,83	0,91	0,75	Bom	250,90	< 0,0001
RNA 3	Calibração	0,85	0,89	0,17	0,84	0,91	0,76	Muito bom	564,20	< 0,0001
MLP 7-8-1	Validação	0,94	0,91	0,19	0,78	0,87	0,67	Bom	174,50	< 0,0001
Área de pinus										
RNA 4	Calibração	0,70	0,69	0,21	0,74	0,84	0,62	Mediano	298,50	< 0,0001
RBF 7-65-1	Validação	0,79	0,81	0,21	0,71	0,82	0,58	Sufrível	116,00	< 0,0001
RNA 5	Calibração	0,72	0,56	0,21	0,79	0,83	0,66	Bom	411,80	< 0,0001
GRNN 7-250-2	Validação	0,88	0,71	0,25	0,64	0,75	0,48	Mau	80,28	< 0,0001
RNA 6	Calibração	0,81	0,67	0,24	0,65	0,76	0,49	Mau	173,70	< 0,0001
MLP 7-11-1	Validação	0,94	0,56	0,25	0,60	0,67	0,41	Péssimo	66,32	< 0,0001
Área de mata nativa										
RNA 7	Calibração	0,66	0,67	0,13	0,86	0,90	0,78	Muito bom	667,40	< 0,0001
GRNN 7-250-2	Validação	0,85	0,81	0,17	0,80	0,87	0,70	Bom	207,60	< 0,0001
RNA 8	Calibração	0,83	0,86	0,17	0,79	0,88	0,69	Bom	414,60	< 0,0001
RBF 7-74-1	Validação	0,96	1,10	0,20	0,77	0,87	0,67	Bom	166,20	< 0,0001
RNA 9	Calibração	0,83	0,79	0,18	0,73	0,83	0,60	Sufrível	259,70	< 0,0001
MLP 7-6-1	Validação	0,96	0,82	0,19	0,67	0,78	0,52	Sufrível	95,12	< 0,0001
Modelo Global										
RNA 10	Calibração	0,66	0,70	0,14	0,89	0,93	0,83	Muito bom	2718,00	< 0,0001
GRNN 12-750-2	Validação	0,80	0,85	0,19	0,81	0,89	0,71	Bom	646,00	< 0,0001
RNA 11	Calibração	0,77	0,85	0,17	0,84	0,91	0,77	Muito bom	1805,00	< 0,0001
RBF 12-100-1	Validação	0,90	1,00	0,21	0,77	0,87	0,68	Bom	517,10	< 0,0001
RNA 12	Calibração	0,91	0,90	0,21	0,76	0,85	0,65	Mediano	975,30	< 0,0001
MLP 12-10-1	Validação	0,96	0,86	0,23	0,75	0,83	0,62	Mediano	436,50	< 0,0001

Fase de calibração

- ✓ Índices de erros semelhantes:
 - ✓ MEA (0,66 a 0,91 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ RMSE (0,56 a 0,94 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ MAPE (0,13 a 0,25);
 - ✓ $d > 0,75$.

Fase de validação

- ✓ Baixa variação dos índices de erros:
 - ✓ MEA (0,79 a 0,96 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ RMSE (0,56 a 1,10 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ MAPE (0,17 a 0,25);
 - ✓ $d > 0,67$.

Sequência de números indica o número de variáveis de entradas, nº de neurônios na primeira camada e nº de neurônios na segunda camada, respectivamente; MEA: erro médio absoluto; RMSE: erro quadrático médio da raiz; MAPE: erro padrão médio absoluto; r: correlação de Pearson; d: índice de concordância de Willmott; c: coeficiente de confiança; Valor-p: probabilidade de ocorrência de H_0 .

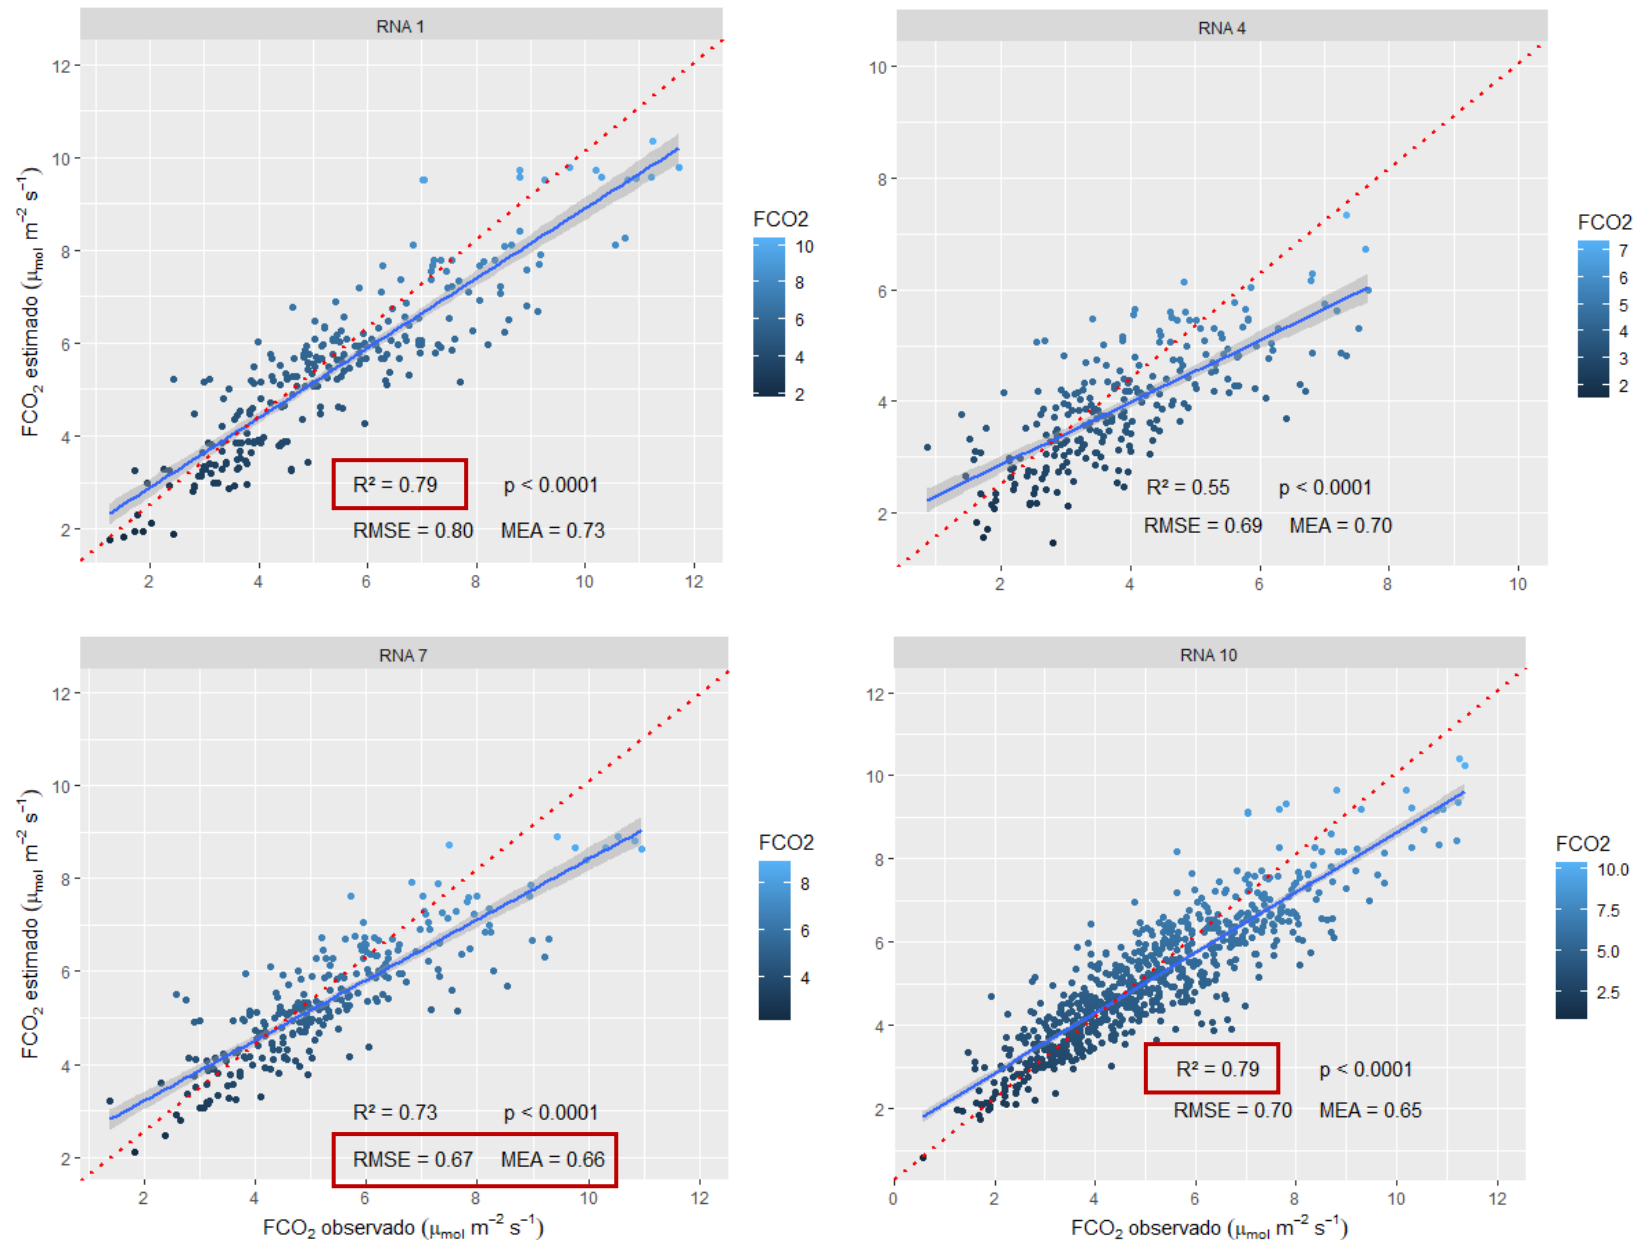
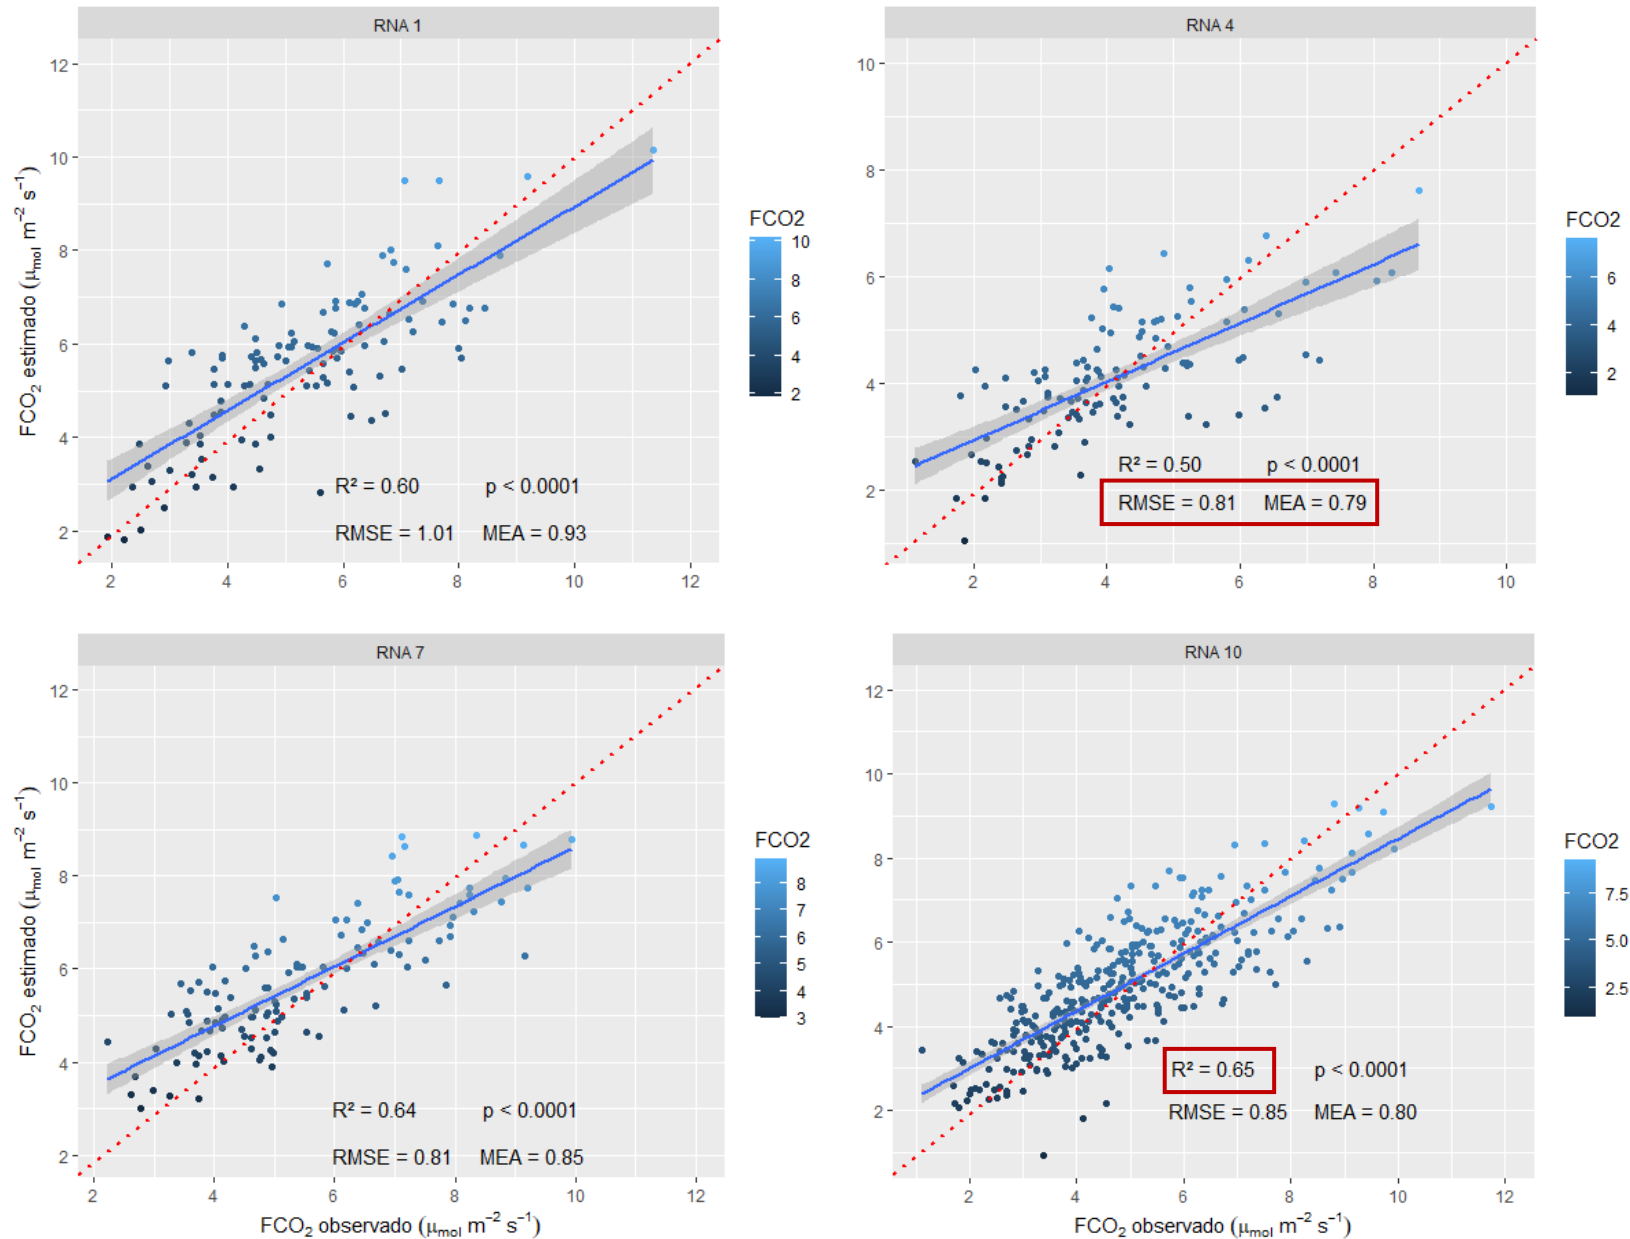



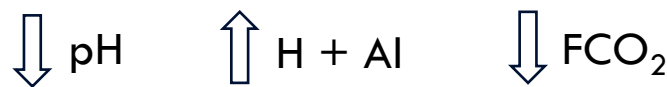
Figura 6. Desempenho do fluxo de CO₂ do solo na fase de calibração das redes neurais artificiais (RNAs).



GRNN

- ✓ Capacidade de aprender o problema mais **rapidamente** mesmo com grande número de conjuntos de dados (Pandey e Mishra, 2017).
- ✓ Maiores números de **camadas ocultas** aos modelos geram maior **complexidade da rede** (Fernandes et al., 2019).
- ✓ Complexidade em modelar a variável FCO₂.

Figura 7. Desempenho do fluxo de CO₂ do solo na fase de validação das redes neurais artificiais (RNAs).

EstC	PLA
<ul style="list-style-type: none"> ✓ Fixação de carbono no solo e práticas agrícolas de manejo e conservação a longo prazo (Maia et al., 2013). ✓ Cerrado brasileiro: grandes reservas de carbono no solo e na biomassa subterrânea (De Miranda et al., 2014). ✓ EstC e emissões de GEE no Brasil. 	<ul style="list-style-type: none"> ✓ Aeração do solo: <ul style="list-style-type: none"> ✓ Entrada de O₂ (atividade de microrganismos aeróbicos); ✓ Saída de O₂ (subproduto da atividade microbiana).
Macro e Micro	pH e H + Al
<ul style="list-style-type: none"> ✓ Sistema de poros, armazenamento e movimento de água e gás no interior dos solos. <p>  </p> <p>Área de eucalipto (5,61 $\mu\text{mol m}^{-2} \text{s}^{-1}$)</p>	<ul style="list-style-type: none"> ✓ Afetam a atividade biológica do solo e respiração radicular; ✓ Tendência de dissociação do CO₂. <p>  </p> <p>Área de pinus (4,06 $\mu\text{mol m}^{-2} \text{s}^{-1}$)</p>

Chen et al., 2018.

Modelagem das emissões de CO₂ de reservatórios
RNAs (MLP, BPNN e **GRNN**),
RLM e MNLR

Freitas et al., 2018.

Predição da FCO₂ em áreas de cana-de-açúcar, SP

RNAs (**MLP** e GRNN)

MAPE = 18,29 %

Sistema de Inferência Adaptativo Neuro-Difuso

Tabela 4. Desempenho dos índices estatísticos para as fases de calibração e validação do sistema de inferência neuro-difuso adaptativo (ANFIS).

Modelos	Fase	MEA	RMSE	MAPE	r
ANFIS 1	Calibração	1,54	2,01	31,16	0,81
Eucalipto	Validação	1,37	1,80	28,84	0,84
ANFIS 2	Calibração	1,36	1,71	37,93	0,77
Pinus	Validação	1,58	1,98	50,46	0,73
ANFIS 3	Calibração	1,69	2,16	32,91	0,78
Mata nativa	Validação	1,50	1,94	31,40	0,80
ANFIS 4	Calibração	1,47	1,88	33,45	0,80
Global	Validação	1,51	1,93	35,64	0,80

Fase de calibração

- ✓ Índices de erros semelhantes:
 - ✓ MEA (1,36 a 1,69 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ RMSE (1,71 a 2,16 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ MAPE (31,16 a 37,93%);
 - ✓ r (0,77 a 0,81).

Fase de validação

- ✓ Índices de erros:
 - ✓ MEA (1,37 a 1,58 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ RMSE (1,80 a 1,98 $\mu\text{mol m}^{-2} \text{s}^{-1}$);
 - ✓ MAPE (28,84 a 50,46);
 - ✓ r (0,73 a 0,84).

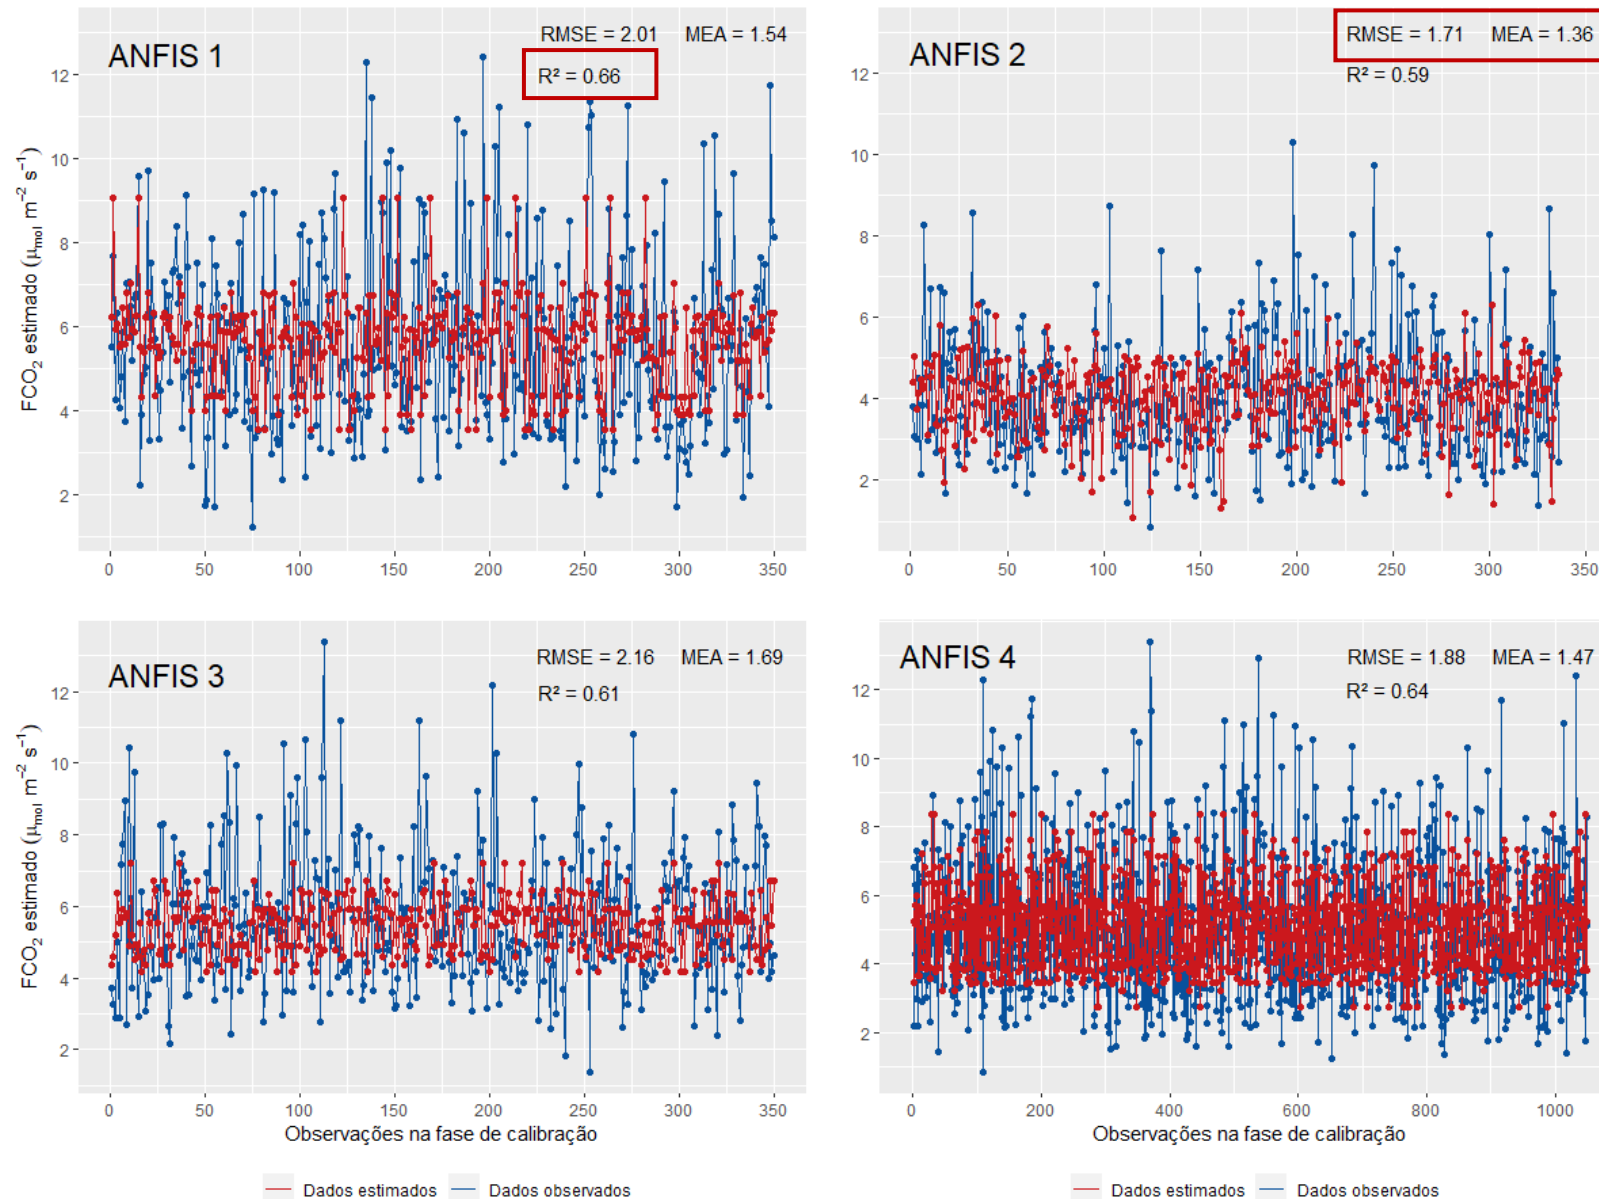


Figura 8. Modelo de emissão de dados reais e modelados do fluxo de CO₂ do solo na fase de calibração do sistema de inferência adaptativo neuro-difuso (ANFIS).

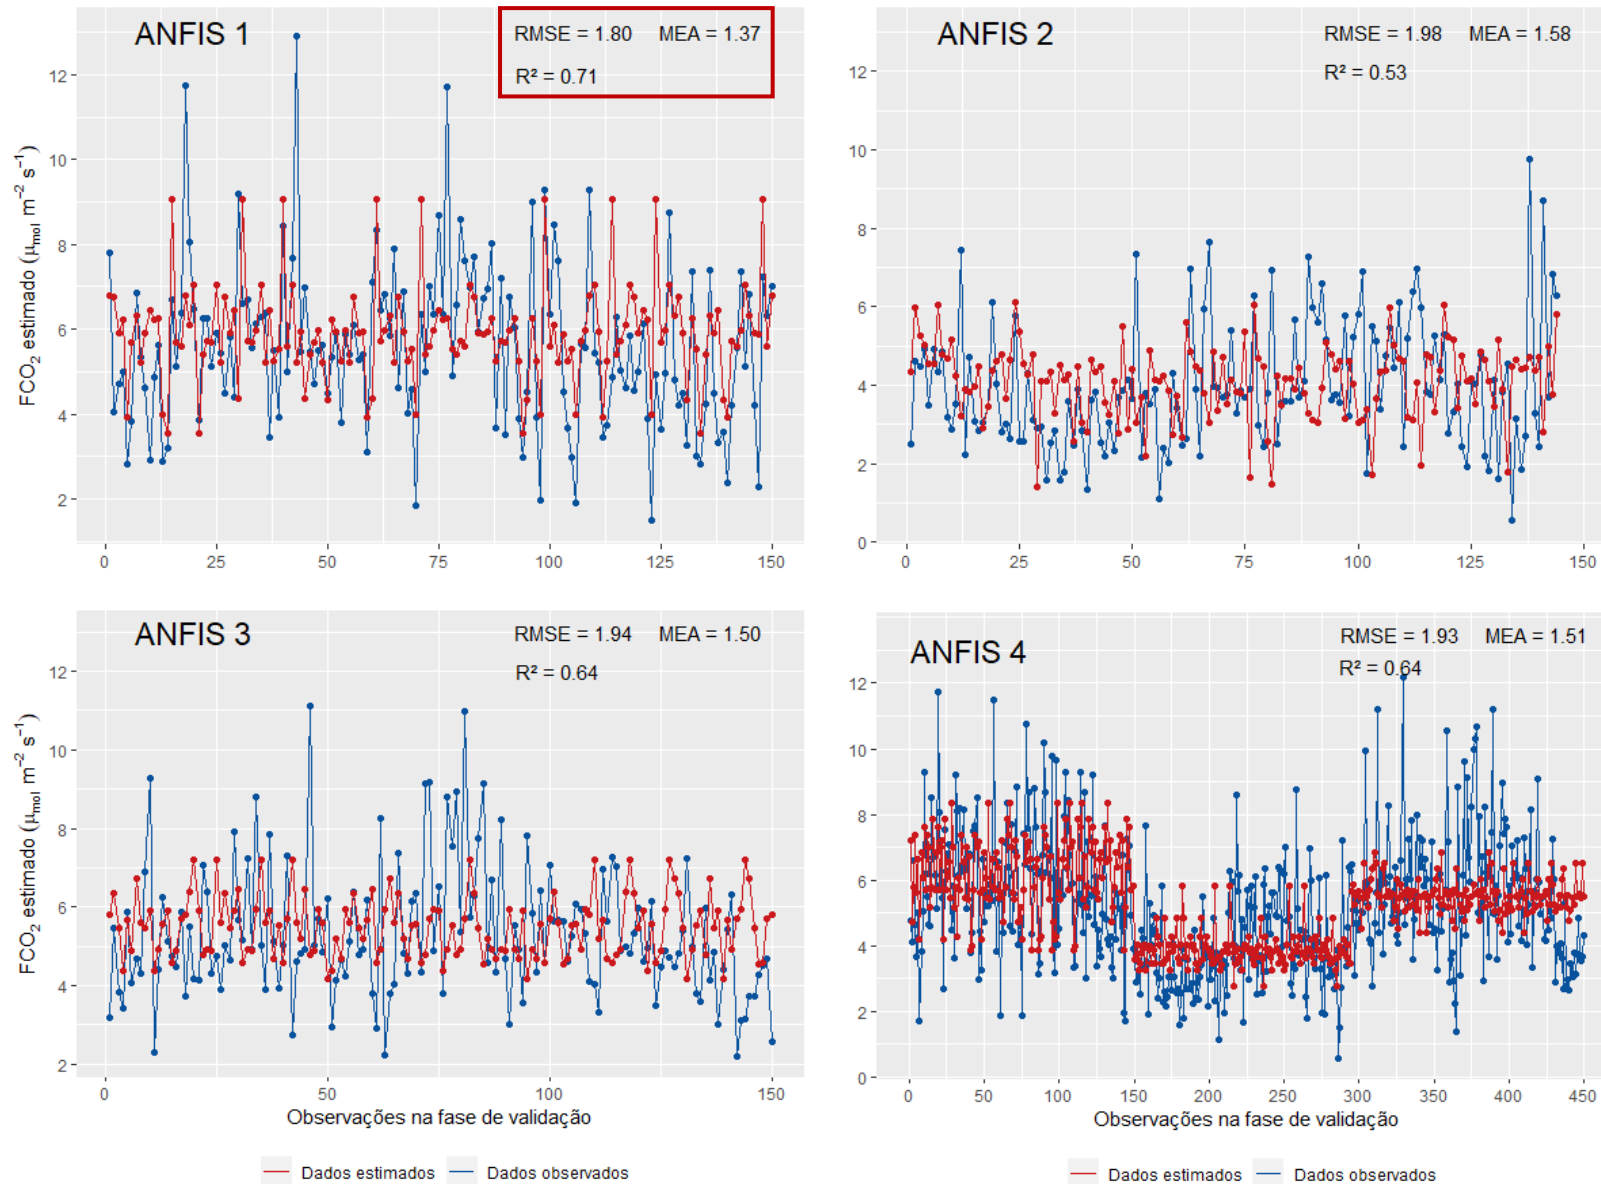


Figura 9. Modelo de emissão de dados reais e modelados do fluxo de CO₂ do solo na fase de validação do sistema de inferência adaptativo neuro-difuso (ANFIS).

Sistema de Inferência Adaptativo Neuro-Difuso

Macro e Micro

- ✓ **Macroporos:** oferecem uma rota menos tortuosa para as moléculas de CO₂;



Atividade microbiana e trocas gasosas (Tavares et al., 2015; 2016).

C/N

- ✓ Grau de **evolução da MOS**;
- ✓ Atividade biológica do solo;
- ✓ Capacidade de produzir **formas de nitrogênio assimiláveis**.

Área de mata nativa (5,53 $\mu\text{mol m}^{-2} \text{s}^{-1}$)

Desempenho preditivo dos modelos

- ✓ **Sensibilidades diferentes** dos atributos físico-químicos entre manejos diferenciados.

- ✓ Índices estatísticos e generalização dos modelos



Conjunto de dados (Fernandes et al., 2020).

- ✓ Semelhança de precisão entre as **fases de calibração e validação** (Sargent et al., 2013).

Gopalakrishnan et al., 2011

Modelagem de gases (NO_x, HC, CO, CO₂ e PM)

RNA e ANFIS


Najafi et al., 2018

Fatores que afetam o rendimento e custo da produção de biodiesel

Bom desempenho preditivo.

RNAs e ANFIS forneceram modelos preditivos para explicar a variabilidade temporal da FCO_2 . Entretanto, as **RNAs apontaram maior desempenho preditivo**, sobretudo a topologia **GRNN**.

Alternativa **eficaz e de baixo custo**, especialmente para **países subdesenvolvidos**, pois a maioria dos atributos que constitui os modelos são comumente determinados em **análises de rotina do solo**.



Estes dados podem ser usados na **formulação de planos estratégicos** que potencializem uma **economia de baixo carbono**, a fim de mitigar as mudanças climáticas e promover o aumento da **resiliência socioambiental**.

Os modelos individuais e global foram altamente **sensíveis à seleção das variáveis de entrada**. Isso evidencia a **heterogeneidade entre os diferentes manejos estudados** e sua influência na variabilidade dos atributos físicos e químicos, que por sua vez afetam diretamente o **fluxo de CO_2 no solo**.



ALEXANDER, M. A.; SCOTT, J. D.; MAHONEY, K.; BARSUGLI, J. Greenhouse gas-induced changes in summer precipitation over Colorado in NARCCAP regional climate models. **Journal of Climate**, v. 26, n. 21, p. 8690-8697, 2013. <https://doi.org/10.1175/JCLI-D-13-00088.1>.

ALTİKAT, S.; Gulbe, A.; Kucukerdem, H. K.; Altikat, A. Applications of artificial neural networks and hybrid models for predicting CO₂ flux from soil to atmosphere. <https://doi.org/10.1007/s13762-020-02799-6>.

ANACHE, J. A.; FLANAGAN, D. C.; SRIVASTAVA, A.; WENDLAND, E. C. Land use and climate change impacts on runoff and soil erosion at the hillslope scale in the Brazilian Cerrado. **Science of The Total Environment**, v. 622, p. 140-151, 2018. <https://doi.org/10.1016/j.scitotenv.2017.11.257>.

BALL, B. C.; SMITH, K. A. Gas movement. In: Smith KA, Mullins CE (Eds.) Soils analysis: physical methods. New York: Marcel Dekker, p. 511-549. 1991.

BATAGLIA, O. C.; FURLANI, A. M. C.; TEIXEIRA, P. F.; FURLANI, P. R.; GALLO, J. R. (1983). **Métodos de análises químicas de plantas**. Campinas, Instituto Agrônômico, p. 48. (Boletim Técnico, 78).

BESALATPOUR, A. A.; AYOUBI, S.; HAJABBASI, M. A.; MOSADDEGHI, M.; SCHULIN, R. Estimating wet soil aggregate stability from easily available properties in a highly mountainous watershed, **CATENA**, v. 111, p. 72-79, 2013. <https://doi.org/10.1016/j.catena.2013.07.001>

BOATENG, E. B.; PILLAY, M.; DAVIS, P. Predicting the level of safety performance using an artificial neural network. In: **International Conference on Human Systems Engineering and Design: Future Trends and Applications**. Springer, Cham, 2018. p. 705-710. https://doi.org/10.1007/978-3-030-02053-8_107.

BORDONAL, R. O.; LAL, R.; RONQUIM, C. C.; DE FIGUEIREDO, E. B.; CARVALHO, J. L. N.; MALDONADO JR, W.; MILORI, D. M. B. P.; LA SCALA JR, N. Changes in quantity and quality of soil carbon due to the land-use conversion to sugarcane (Saccharum officinarum) plantation in southern Brazil. **Agriculture, ecosystems & environment**, v. 240, p. 54-65, 2017. <https://doi.org/10.1016/j.agee.2017.02.016>.

BRASIL. Third National Communication of Brazil to the United Nations Framework **Convention on Climate Change Brasilia**. [S.l.: s.n.], 2016. [Disponível em: <https://unfccc.int/resource/docs/natc/branc3v3.pdf>. Acesso em: 25. agosto. 2019.

CAMARGO, A. P.; SENTELHAS, P. C. Avaliação do desempenho de diferentes métodos de estimativa da evapotranspiração potencial no Estado de São Paulo, Brasil. **Revista Brasileira de agrometeorologia**, v. 5, n. 1, p. 89-97, 1997.

CARVALHO, J. L. N.; CERRI, C. E. P.; FEIGL, B. J.; PÍCCOLO, M. D. C.; GODINHO, V. P.; CERRI, C. C. Carbon sequestration in agricultural soils in the Cerrado region of the Brazilian Amazon. **Soil and Tillage Research**, v. 103, n. 2, p. 342-349, 2009. <https://doi.org/10.1016/j.still.2008.10.022>.

CHEN, Z.; YE, X.; HUANG, P. Estimating carbon dioxide (CO₂) emissions from reservoirs using artificial neural networks. **Water**, v. 10, n. 1, p. 26, 2018. <https://doi.org/10.3390/w10010026>.

CRUZ, C. D.; REGAZZI, A. J. (1994). Modelos Biométricos Aplicados Ao Melhoramento Genético. Universidade Federal de Viçosa, Viçosa.

DE CARVALHO, M. A. C.; PANOSSO, A. R.; TEIXEIRA, E. E. R.; ARAÚJO, E. G.; BRANCAGLIONI, V. A.; DALLACORT, R. Multivariate approach of soil attributes on the characterization of land use in the southern Brazilian Amazon. **Soil and Tillage Research**, v. 184, p. 207-215, 2018. <https://doi.org/10.1016/j.still.2018.08.004>.

DE FIGUEIREDO, E. B.; JAYASUNDARA, S.; DE OLIVEIRA BORDONAL, R.; BERCHIELLI, T. T.; REIS, R. A.; WAGNER-RIDDLE, C.; LA SCALA JR, N. Greenhouse gas balance and carbon footprint of beef cattle in three contrasting pasture-management systems in Brazil. **Journal of cleaner production**, v. 142, p. 420-431, 2017.

DE MIRANDA, S. D. C.; BUSTAMANTE, M.; PALACE, M.; HAGEN, S.; KELLER, M.; FERREIRA, L. G. Regional variations in biomass distribution in Brazilian savanna woodland. **Biotropica**, v. 46, n. 2, p. 125-138, 2014. <https://doi.org/10.1111/btp.12095>.

DE OLIVEIRA, V. A.; DE MELLO, C. R.; BESKOW, S.; VIOLA, M. R.; SRINIVASAN, R. Modeling the effects of climate change on hydrology and sediment load in a headwater basin in the Brazilian Cerrado biome. **Ecological Engineering**, v. 133, p. 20-31, 2019. <https://doi.org/10.1016/j.ecoleng.2019.04.021>

DORODNIKOV, M.; KUZYAKOV, Y.; FANGMEIER, A.; WIESENBERG, G. L. B. C and N in soil organic matter density fractions under elevated atmospheric CO₂: Turnover vs. Stabilization. **Soil Biology and Biochemistry**, Oxford, v. 43, n. 3, p. 579-589, 2011. <https://doi.org/10.1016/j.soilbio.2010.11.026>.

DOS SANTOS MACIEL, L.; BALLINI, R.; DA SILVEIRA, R. L. F. Apreçamento de opções sobre taxa de câmbio R \$/US \$ negociadas no Brasil: uma comparação entre os modelos Black e redes neurais artificiais. **Revista de Administração**, v. 47, n. 1, p. 96-111, 2012. <https://doi.org/10.5700/rausp1028>.

EMBRAPA – Empresa Brasileira de Pesquisa Agropecuária. **Manual de métodos de análise de solo**. 3. ed. Rio de Janeiro: Embrapa Solos. 2017.

FARHATE, C. V. V.; DE SOUZA, Z. M.; DE MEDEIROS OLIVEIRA, S. R.; TAVARES, R. L. M.; CARVALHO, J. L. N. Use of data mining techniques to classify soil CO₂ emission induced by crop management in sugarcane field. **PLoS one**, v. 13, n. 3, 2018. <https://doi.org/10.1371/journal.pone.0193537>

FERNANDES, M. M. H.; COELHO, A. P.; DA SILVA, M. F.; BERTONHA, R. S.; DE QUEIROZ, R. F.; FURLANI, C. E. A.; FERNANDES, C. Estimation of soil penetration resistance with standardized moisture using modeling by artificial neural networks. **Catena**, v. 189, p. 104505, 2020. <https://doi.org/10.1016/j.catena.2020.104505>.

FERNANDES, M. M. H.; COELHO, A. P.; FERNANDES, C.; DA SILVA, M. F.; MARTA, C. C. D Estimation of soil organic matter content by modeling with artificial neural networks. **Geoderma**, v. 350, p. 46-51, 2019. <https://doi.org/10.1016/j.geoderma.2019.04.044>.

FIGUEIREDO, E. B. D.; PANOSSO, A. R.; BORDONAL, R. D. O.; TEIXEIRA, D. D. B.; BERCHIELLI, T. T.; LA SCALA JR, N. Soil CO₂-C emissions and correlations with soil properties in degraded and managed pastures in Southern Brazil. **Land Degradation & Development**, v. 28, n. 4, p. 1263-1273, 2017. <https://doi.org/10.1002/ldr.2524>.

FLANAGAN, L. B.; SHARP, E. J.; LETTS, M. G. Response of plant biomass and soil respiration to experimental warming and precipitation manipulation in a Northern Great Plains grassland. **Agricultural and Forest Meteorology**, v. 173, p. 40-52, 2013. <https://doi.org/10.1016/j.agrformet.2013.01.002>.

FREITAS, L. P. S.; LOPES, M. L. M.; CARVALHO, L. B.; PANOSSO, A. R.; LA SCALA JR, N.; FREITAS, R. L. B.; MINUSSI, C. R.; LOTUFO, A. D. P. Forecasting the spatiotemporal variability of soil CO₂ emissions in sugarcane areas in southeastern Brazil using artificial neural networks. **Environmental monitoring and assessment**, v. 190, n. 12, p. 741, 2018. <https://doi.org/10.1007/s10661-018-7118-0>.

GHIASI, M. M.; ARABLOO, M.; MOHAMMADI, A. H.; BARGHI, T. Application of ANFIS soft computing technique in modeling the CO₂ capture with MEA, DEA, and TEA aqueous solutions. **International Journal of Greenhouse Gas Control**, v. 49, p. 47-54, 2016. <https://doi.org/10.1016/j.ijggc.2016.02.015>.

HAYKIN, S. **Redes neurais: princípios e prática**. (2 ed.), Bookman, Porto Alegre (2001).

IPCC - Intergovernmental Panel on Climate Change. Climate change 2007: **The physical science basis. Summary for policymakers**, Geneva, Suíça. Disponível em: <http://www.ipcc.ch/publications_and_data/publications_ipcc_fourth_assessment_report_wg1_report_the_physical_science_basis.htm>. Acesso em 29 set. 2007.

IPCC, 2014. **Intergovernmental panel on climate change**. In: Smith, P., Bustamante M. (Eds.), Working Group III Contribution to the IPCC 5th Assessment Report "Climate Change 2014: Mitigation of Climate Change" that was Accepted but Not Approved in Detail by the 12th Session of Working Group III and the 39th Session of the IPCC on April 12 2014 in Berlin, Germany (2014).

JANG, J. S. R. ANFIS: adaptive-network-based fuzzy inference system. **IEEE transactions on systems, man, and cybernetics**. <http://doi.org/10.1109/21.256541>
Johnson, D. W. Acid deposition and the acidification of soils and water. *Ecological studies (USA)*. v. 59., 1986.

KAAB, A.; SHARIFI, M.; MOBLI, H.; NABAVI-PELESARAEI, A.; CHAU, K. W. Combined life cycle assessment and artificial intelligence for prediction of output energy and environmental impacts of sugarcane production. **Science of the Total Environment**, v. 664, p. 1005-1019, 2019. <https://doi.org/10.1016/j.scitotenv.2019.02.004>

KANG, S., KIM, S., OH, S., LEE, D. Predicting spatial and temporal patterns of soil temperature based on topography, surface cover, and air temperature. **Forest Ecology and Management**, v. 136, n. 1-3, p. 173-184, 2000. [https://doi.org/10.1016/S0378-1127\(99\)00290-X](https://doi.org/10.1016/S0378-1127(99)00290-X)

KASHI, H.; EMAMGHOLIZADEH, S.; GHORBANI, H. Estimation of soil infiltration and cation exchange capacity based on multiple regression, ANN (RBF, MLP), and ANFIS models. **Communications in soil science and plant analysis**, v. 45, n. 9, p. 1195-1213, 2014. <https://doi.org/10.1080/00103624.2013.874029>.

KHAN, M. Z.; KHAN, M. F. Application of ANFIS, ANN and fuzzy time series models to CO₂ emission from the energy sector and global temperature increase. **International Journal of Climate Change Strategies and Management**, v. 11, n. 5, p. 622-642, 2019. <https://doi.org/10.1108/IJCCSM-01-2019-0001>

LAMPARTER, A.; BACHMANN, J.; GOEBEL, M. O.; WOCH, S. K. Carbon mineralization in soil: Impact of wetting-drying, aggregation and water repellency. **Geoderma**, v. 150, n. 3-4, p. 324-333, 2009. <https://doi.org/10.1016/j.geoderma.2009.02.014>.

LI, D.; NIU, S.; LUO, Y. Global patterns of the dynamics of soil carbon and nitrogen stocks following afforestation: a meta-analysis. **New Phytologist**, v. 195, n. 1, p. 172-181, 2012. <https://doi.org/10.1111/j.1469-8137.2012.04150.x>

MAIA, S. M. F.; CARVALHO, J. L. N.; CERRI, C. E. P.; LAL, R.; BERNOUX, M.; GALDOS, M. V.; CERRI, C. C. Contrasting approaches for estimating soil carbon changes in Amazon and Cerrado biomes. **Soil and Tillage Research**, v. 133, p. 75-84, 2013. <https://doi.org/10.1016/j.still.2013.06.002>.

MAIER, H. R.; DANDY, G.C. Neural network based modelling of environmental variables: a systematic approach. **Mathematical and Computer Modelling**, v. 33, n. 6-7, p. 669-682, 2001. [https://doi.org/10.1016/S0895-7177\(00\)00271-5](https://doi.org/10.1016/S0895-7177(00)00271-5).

MAROUFPOOR, S.; MAROUFPOOR, E.; BOZORG-HADDAD, O.; SHIRI, J.; YASEEN, Z. M. Soil moisture simulation using hybrid artificial intelligent model: Hybridization of adaptive neuro fuzzy inference system with grey wolf optimizer algorithm. **Journal of Hydrology**, v. 575, p. 544-556, 2019. <https://doi.org/10.1016/j.jhydrol.2019.05.045>.

MILORI, D. M. B. P.; GALETI, H. V. A.; MARTIN-NETO, L.; DIECKOW, J.; GONZÁLEZ-PÉREZ, M.; BAYER, C.; SALTON, J. Organic matter study of whole soil samples using laser-induced fluorescence spectroscopy. *Soil Science Society of America Journal*. v. 70, n. 1, p. 57-63, 2006. <https://doi.org/10.2136/sssaj2004.0270>.

MOITINHO, M. R.; PADOVAN, M. P.; PANOSSO, A. R.; TEIXEIRA, D. D. B.; FERRAUDO, A. S.; LA SCALA JR, N. On the spatial and temporal dependence of CO₂ emission on soil properties in sugarcane (*Saccharum spp.*) production. **Soil and Tillage Research**, v. 148, p. 127-132, 2015. <https://doi.org/10.1016/j.still.2014.12.012>.

NAJAFI, B.; ARDABILI, S. F.; SHAMSHIRBAND, S.; CHAU, K. W.; RABCZUK, T. Application of ANNs, ANFIS and RSM to estimating and optimizing the parameters that affect the yield and cost of biodiesel production. **Engineering Applications of Computational Fluid Mechanics**, v. 12, n. 1, p. 611-624, 2018. <https://doi.org/10.1080/19942060.2018.1502688>.

NOOJIPADY, P.; MORTON, C. D.; MACEDO, N. M.; VICTORIA, C. D.; HUANG, C.; GIBBS, K. H.; BOLFE, L. E. Forest carbon emissions from cropland expansion in the Brazilian Cerrado biome. **Environmental Research Letters**, Bristol, v. 12, n. 2, p. 025004, 2017. <https://doi.org/10.1088/1748-9326/aa5986>



Obrigado pela atenção!!!

Engenheiro Ambiental e de Energias Renováveis

E-mail: canteralkleve@gmail.com

kleve.canteral@unesp.br